

철도 자기 경로 검출의 학습형 시간 정련은 이동평균 기준선을 능가하는가

Does Learned Temporal Refinement Outperform a Moving-Average Baseline in Railway Ego-Path Detection?

분기부 평가 데이터셋 구축과 통제 비교

김백현 · 황현철 †

한국철도기술연구원 Korea Railroad Research Institute

연구 배경 — 자기 경로 검출이 가장 어려운 지점

분기부의 구조적 난점

- 갈라지는 유일한 지점 진로 판단이 가장 중요한 곳
- 통과 직후 근거가 사라짐 진로를 결정하는 텀레일이 화면 아래로 이탈
- 현재 프레임만으로는 불능 어느 갈래를 택했는지 확정할 수 없음

선행 연구가 남긴 숙제

- Laurent[1] 이 구간을 “불확실 기간” 으로 규정
- 제안 순환 신경망 (RNN) 결합으로 보완
- 미해결 “포괄적 시계열 데이터셋이 없어” 검증 못 함

검증에 필요한 두 가지

- ① **시계열 평가 데이터** — 분기기 통과 전후를 담은 시퀀스가 있어야 한다 .
- ② **적절한 비교 기준** — 흔히 간과되는 쪽이다 . 학습형 시간 모듈은 통상 단일 프레임 모델과만 비교되고 , 학습이 필요 없는 시간 필터와는 비교되지 않는다 .
시간적 안정성은 이동평균만으로도 얻을 수 있다 . 학습형 모듈이 그 기준선을 넘지 못한다면 추가 파라미터와 학습 비용은 정당화되지 않는다 .

연구 질문과 기여

연구 질문

학습형 시간 정련은 학습이 필요 없는 이동평균 기준선을 능가하는가 ?

데이터

- 분기부 평가 데이터셋 276 이벤트 · 47 개 원본 영상 · 18 개 지역
- 텅레일 식별 가능성의 정량 기준 실효 해상도로 데이터 품질 관리

규명

- 시퀀스 간격 정합의 효과 안정성 2.6 배, 그러나 정확도는 불변
- 인도메인 지표의 한계 이 차이는 학습 도메인 지표로 드러나지 않음

핵심 비교와 부정 결과

- 학습형 정련 대 이동평균 거의 같은 정확도 비용에서 EMA 가 약 6 배의 안정성 개선
- 다중 가설 정식화의 사전 검증 가설이 0.4 px 로 붕괴 — 상한조차 단일 경로를 넘지 못함
- 방법론적 제언 학습형 시간 모듈은 이동평균 기준선과 비교되어야 한다

관련 연구

자기 경로 검출

- Laurent[1] 종단간 딥러닝으로 정식화, 백본 x 헤드 조합 비교
- 회귀 방식 앵커별 x 좌표와 경로 상한을 직접 예측 — 디코더 없이 낮은 지연
- 헤지 특성 모호할 때 두 궤도의 중간을 예측

시간적 확장

- 특징맵 수준 융합 영상 근거를 함께 사용
- 출력 수준 정련 ← 본 연구 대상 프레임별 네트워크 동결, GRU 가 최근 출력 벡터를 읽어 잔차 예측
- 영행렬 초기화 학습 전에는 프레임별 예측과 동일 출력

비학습 대안

- 인과적 이동평균 · 지수이동평균 추가 학습 없이 프레임 간 흔들림 감소
- 대가는 지연 (lag) 대상이 실제로 변하는 순간 반응이 늦음
- 본 논문 이 고전적 대안을 학습형 정련부와 동일 지표로 비교

철도 인지 데이터셋

- RailSem19[2] 주행 시점 정지 영상 약 8,500 장
- OSDaR23[3] 다중 센서 연속 주행 시퀀스
- 공백 두 데이터셋 모두 분기부 통과 전후를 집중적으로 담고 있지 않음

분기부 평가 데이터셋 — 수집과 구성

이벤트 정의

- **기관사 시점 (cab view) 영상** 분기기 통과 장면을 이벤트 단위로 절단
- 20 초 창 · 4 fps · 81 프레임 프레임 간격 0.25 초, 폭 1280 px
- 분기 (facing, split) 만 유지 합류 (trailing)· 고정 카메라 · 모형철도 제외

규모와 분포

- **276 이벤트** 47 개 원본 영상 · 18 개 지역
- **지역 분포** 영국 77 · 일본 34 · 슬로베니아 25 · 독일 22 · 한국 19 · 스위스 17 등
- **평가 표본** 증화 표본 30 이벤트 / 2,422 프레임

라벨과 해석상의 주의

- **라벨 생성** SAM 2[4] 비디오 마스크 전파 + 학습된 세그멘테이션 모델 병용, 육안 검수
- **계열 분리** 라벨 생성 모델은 세그멘테이션 계열 — 비교 대상인 회귀 계열 어느 쪽에도 유리하지 않음
- **절대 IoU 의 의미** 자동 라벨과의 일치도로 해석하며, 본 논문의 결론은 모델 간 상대 비교에 근거

텀레일 식별 가능성 기준 — 명목이 아니라 실효 해상도

문제

- 모두 같은 1280×720 해상도 표기로는 판별 불가
- 업스케일 영상 화소 수는 같지만 분기기 세부가 없음
- 판별 대상 텀레일 밀착 여부



그림 1. 좌: 재추출 전 ($\leq 720p$ 원본에서 절단) · 우: 동일 구간을 1080p 에서 재추출

정량 기준

$$hi = \text{mean} | I - \text{up}(\text{down}(I, 2), 2) |$$

- 대상 영역 중앙-하단 (세로 50-95%, 가로 22-78%)
- 의미 화소율 절반을 넘는 고주파 성분의 양 — 업스케일본은 0 에 가까움

육안 검증으로 확인한 임계값

$hi = 2.63$ 침목이 뭉개져 텀레일 판별 불가

$hi = 3.00$ 레일 윤곽과 침목이 분리되어 판별 가능

따라서 채택 기준은 $hi \geq 3.0$

데이터 품질 관리 — 새 영상 대신 같은 구간의 재추출

단계	이벤트 수
초기 수집분	318
실효 해상도 기준 미달 99 개 (31%) 제외	219
동일 구간 고해상도 재추출로 복구	275
육안 확인한 신규 수집분 반영	276

근본 원인은 수집 설정이었다

- 원본 32 편 중 29 편이 1080p 이상 4K 10 편 — 그런데 720p 이하로 내려받았다
- 따라서 새 영상을 찾지 않았다 동일 구간을 고해상도로 다시 잘라 56 개 복구
- 큐레이션 보존 원본 시각·창 정보를 그대로 써서 분기 / 합류 분류가 유지됨

결과

최종 데이터셋 전체가 기준을 통과한다 .

재추출본의 실효 해상도 중앙값은 **4.89** 로 , 삭제 대상이었던 값 (2 점대) 의 약 두 배다 .

명목 해상도만 확인했다면 99 개의 판별 불가 이벤트가 평가셋에 남고 , 그중 상당수는 재추출로 되살릴 수 있다는 사실도 발견되지 않았을 것이다 .

평가 프로토콜 — 구간 정의

구간	범위	의미
접근	-6 ~ 0 s	분기부가 전방에 보이는 구간
직후	0 ~ 2.5 s	통과 직후, 경로가 실제로 변하는 구간
불확실	2.5 ~ 6 s	분기부가 시야를 벗어난 뒤, 진로 확인 전
후기	6 ~ 10 s	진로가 확정된 이후

왜 초 단위로 규정하는가

- 구간 경계는 표본화율로 환산 각 이벤트의 4 fps 로 프레임 인덱스에 대응
- 혼동의 대가 프레임 단위와 초 단위를 혼동하면 구간 폭이 4 배로 어긋난다
- 따라서 본 프로토콜은 모든 경계를 초로 규정한다




그림 2. 이벤트 구조와 평가 구간 정의

왜 불확실 구간이 관심 대상인가

네 구간 중 시간 정보가 이득을 줄 수 있는 곳은 여기뿐이다.

접근 구간에는 분기부가 화면에 있어 현재 프레임만으로 판단이 되고, 후기 구간에는 궤도 정렬로 진로가 이미 확인된다.

불확실 구간은 근거가 화면에서 사라진 뒤 아직 확인되기 전 — 과거 프레임 말고는 참고할 것이 없는 유일한 구간이다.

평가 프로토콜 — 지표

IoU — 정확도

- **정의** 예측한 좌·우 레일이 이루는 영역과 라벨 영역의 교집합 / 합집합
- **한계** 라벨이 필요하며, 자동 라벨 비중이 높아 절대값은 일치도로 읽어야 함

프레임 간 지터 — 안정성

- **정의** 연속 두 프레임의 예측 경로를 공통 높이 구간에서 비교한 평균 $|\Delta x|$ (px)
- **장점** 정답 라벨이 필요 없다 — 값이 클수록 예측이 불안정
- **근거** Laurent[1] 가 불확실성 지표로 제안한 “예측의 주저 (hesitancy)” 의 정량화

두 지표를 함께 보아야 하는 이유

평활은 공짜가 아니다. 지터는 얼마든지 줄일 수 있지만 그 대가로 지연이 생겨 정확도를 잃는다.

따라서 본 논문은 안정성 개선율과 IoU 손실을 함께 제시하고, 정확도 1 단위를 지불하고 얻는 안정성 개선율을 **효율**로 정의해 방법 간 비교의 축으로 삼는다.

비교 대상

기준 모델 (base)

- EfficientNet-B3 백본의 회귀형 단일 프레임 검출기

학습형 시간 정련 — GRU 0.46 M (base 대비 +3.2%)

- 구조 base 동결, 최근 5 개 출력 벡터 (각 129 차원) 를 GRU(은닉 256, 1 층) 가 읽어 잔차 예측
- rnn 단일 이미지에서 크롭 창을 보간한 합성 유사 시퀀스 — 선행 구현의 기본값
- rnn-1fps OSDaR23(10 fps) 에서 stride 10 으로 표본화한 실제 시퀀스
- rnn-4fps 동일 영상 stride 3(3.33 fps) — 평가 영상의 4 fps 에 근접
- rnn-occ 분기부 가림을 모사하는 증강으로 학습
- 통제쌍 1fps 와 4fps 는 표본화 간격만 다르고 나머지 설정 동일

학습 불필요 시간 필터

- 적용 대상 base 의 원시 예측 벡터
- 좌표계 정렬 크롭 창이 프레임마다 이동하므로 과거 예측을 현재 좌표계로 재투영 후 결합
- boxcar-K 최근 K 개 예측의 단순 평균
- EMA- α $out[t] = \alpha \cdot x[t] + (1-\alpha) \cdot out[t-1]$, $out[0] = x[0]$
- 파라미터 없음 — 후처리 한 줄

두 계열은 같은 정보 (과거 예측) 만 본다 . **차이는 그 정보를 학습으로 쓰느냐, 고정된 규칙으로 쓰느냐뿐이다 .**

결과 ① 구간별 프레임 간 지터 (px, 괄호는 base 대비 개선율)

모델	접근 - 6~0 s	직후 0~2.5 s	불확실 2.5~6 s	후기 6~10 s
base	2.96	2.45	3.22	3.18
rnn	2.96 (-0.2%)	2.46 (-0.3%)	3.07 (+4.5%)	3.14 (+1.3%)
rnn-occ	4.15 (-40.6%)	2.82 (-15.1%)	3.78 (-17.6%)	4.08 (-28.3%)
rnn-1fps	3.11 (-5.3%)	2.30 (+5.8%)	3.03 (+5.7%)	3.12 (+1.8%)
rnn-4fps	3.13 (-5.8%)	2.41 (+1.6%)	2.74 (+14.9%)	3.10 (+2.4%)
base+boxcar3	2.54 (+14.2%)	1.92 (+21.5%)	2.46 (+23.6%)	2.56 (+19.4%)
base+EMA0.5	2.45 (+17.3%)	1.93 (+21.2%)	2.44 (+24.0%)	2.37 (+25.4%)
base+boxcar5	2.41 (+18.6%)	1.73 (+29.4%)	2.16 (+32.8%)	2.17 (+31.7%)

읽는 법

학습형 정련 중 최고는 rnn-4fps 로 불확실 구간 **+14.9%**. 그러나 같은 구간에서 EMA0.5 는 **+24.0%**, 필터 계열은 전 구간에서 고르게 앞선다.

rnn-occ 는 모든 구간에서 base 보다 나쁘다 — 6.4 절에서 원인을 다룬다.

결과 ② 구간별 IoU (라벨 대비)

모델	접근	직후	불확실	후기
base	0.9562	0.9598	0.9445	0.9481
rnn	0.9538	0.9577	0.9465	0.9471
rnn-occ	0.9462	0.9542	0.9399	0.9399
rnn-1fps	0.9378	0.9470	0.9361	0.9346
rnn-4fps	0.9371	0.9472	0.9325	0.9358
base+boxcar3	0.9356	0.9372	0.9322	0.9314
base+EMA0.5	0.9365	0.9400	0.9349	0.9354
base+boxcar5	0.9108	0.9150	0.9095	0.9071
(프레임 수 n)	720	300	420	480

전체를 관통하는 관찰

시간 정보의 이득은 정확도가 아니라 안정성으로만 나타난다.

어떤 시간 모델도 base 의 IoU 를 상회하지 못한다 — 불확실 구간의 rnn 이 유일한 예외이며 그 폭도 +0.0020 에 그친다.

결과 ③ 시퀀스 간격 정합의 효과

통제쌍

- rnn-1fps 대 rnn-4fps 표본화 간격만 다르고 나머지 설정은 동일

지표	rnn-1fps	rnn-4fps
불확실 구간 안정성	+5.7%	+14.9%
IoU 손실	-0.0132	-0.0140
학습 도메인 Test IoU	0.98459	0.98480
최저 검증 손실	0.02073	0.02070

간격을 맞추면 안정성만 오른다

불확실 구간 개선이 **+5.7% → +14.9%** 로 2.6 배 증가한다. 시간 정보가 실제로 필요한 구간에 효과가 집중된다.

반면 정확도는 개선되지 않는다 (-0.0132 대 -0.0140 으로 사실상 동일). 간격 정합은 정련부가 과거 궤적을 더 잘 활용하게 하지만, 그 활용이 정확도로 환산되지는 않는다.

인도메인 지표로는 보이지 않는다

두 모델의 학습 도메인 지표는 구분되지 않는다.

시간 모델의 거동은 시퀀스의 시간 구조에 의존하므로, 프레임 간격이 다른 도메인에 적용할 때 인도메인 지표만으로 판단해서는 안 된다.

결과 ④ 핵심 — 학습형 정련 대 이동평균

모델	지터	안정성	IoU 손실	효율
base	2.95	기준	—	—
rnn	2.91	+1.4%	-0.0008	(미미)
rnn-occ	3.71	-25.7%	-0.0071	음 (악화)
rnn-1fps	2.89	+1.9%	-0.0132	144
rnn-4fps	2.84	+3.6%	-0.0140	259
base+boxcar3	2.37	+19.7%	-0.0180	1,094
base+EMA0.5	2.30	+22.1%	-0.0154	1,434
base+boxcar5	2.12	+28.2%	-0.0415	680




그림 3. (a) 불확실 구간의 한 프레임 (b) 프레임 간 흔들림의 시간 변화

0.46 M 파라미터는 정당화되지 않는다

거의 같은 정확도 비용 (-0.0140 대 -0.0154) 에서 EMA 는 안정성을 **약 6 배** 개선한다 (+3.6% 대 +22.1%). 효율로는 259 대 1,434 로 **5.5 배** . 합성 시퀀스로 학습한 rnn 은 항등 함수에 가깝게 수렴해 비용도 이득도 거의 없다 .

부정 결과 — 가림 증강과 다중 가설 정식화

가림 증강의 재검토 (rnn-occ)

- 모든 구간에서 최하위 지터 - 25.7%, IoU -0.0071
- 원인 증강이 모사하는 실패 모드와 실제 실패 모드의 불일치
- 하단 차폐가 가르치는 것 “경로가 가려졌다” — 그러나 실제 분기부에서 레일은 계속 보인다
- 실제 불확실성 두 갈래 중 어느 쪽인지 모르는 이산적 모호성
- 방증 정련부가 base 에서 크게 이탈할수록 IoU 단조 감소 (rnn 2.36 px, rnn-occ 5.87 px)

다중 가설 정식화의 사전 검증 (K=2)

구간	단일 경로	oracle	oracle - 단일	가설 간 거리
접근	0.9562	0.9551	-0.0011	0.47 px
직후	0.9598	0.9601	+0.0003	0.43 px
불확실	0.9445	0.9365	-0.0080	0.41 px
후기	0.9481	0.9463	-0.0018	0.42 px

왜 가설이 붕괴하는가

oracle 이 단일 경로를 넘는 구간이 없고 (최대 +0.0003), 두 가설의 거리는 0.41-0.47 px 로 사실상 같은 경로다 .

승자독식 학습이 가설을 특화시키려면 이미지 조건부 분포가 다봉이어야 하는데 , 텅레일 방향은 이미지에 관측되므로 대부분의 학습 이미지에서 정답 갈래가 결정된다 . 진정으로 모호한 프레임은 분기부가 시야를 벗어난 이후뿐이며 — 그 데이터는 본 논문의 평가셋과 같은 성격이라 , 학습에 쓰면 평가셋이 소진된다 .

결론

핵심 결론

시간 정보의 이득은 정확도가 아니라 안정성으로만 나타났다.

학습형 정련부는 단순 지수이동평균에 크게 못 미친다 — 거의 동일한 정확도 비용에서 EMA 가 약 6 배의 안정성 개선, 효율로는 5.5 배 차이.

따라서 0.46 M 파라미터와 별도 학습을 요구하는 출력 수준 시간 정련은 후처리 필터 대비 정당화되지 않는다.

기여 요약

- **평가 기반 마련** 분기부 276 이벤트 데이터셋 + 실효 해상도 품질 기준
- **실증적 답** Laurent[1] 가 제안만 하고 검증하지 못한 시간 확장에 대한 답
- **방법론적 제안** 학습형 시간 모듈은 이동평균 기준선과 비교되어야 한다
- **부정 결과 보고** 가림 증강의 역효과, 다중 가설 정식화의 붕괴

향후 연구

- **특징맵 수준 시간 융합** 예측 벡터만이 아니라 영상 근거를 함께 활용
- **적응적 필터** 예측 불확실성에 따라 평활 강도를 조절 — 흔들릴 때만 강하게
- **도메인 적응** ← 우선순위 높음 시간축 개선 폭은 IoU ± 0.005 인 반면 학습 도메인 (0.98) 과 평가 도메인 (0.95) 의 격차는 그보다 훨씬 크다