

철도 자기 경로 검출의 학습형 시간 정련은 이동평균 기준선을 능가하는가: 분기부 평가 데이터셋 구축과 통제 비교

Does Learned Temporal Refinement Outperform a Moving-Average Baseline in Railway Ego-Path Detection? Construction of a Turnout Evaluation Dataset and a Controlled Comparison

김백현¹ · 황현철¹ †

¹ 한국철도기술연구원 (Korea Railroad Research Institute)

주저자: 김백현 (bhkim@krri.re.kr)

† 교신저자: 황현철 (hchwang@krri.re.kr)

Baek-Hyun Kim¹ · Hyeon-Chyeol Hwang¹ †

국문 초록

철도 자율주행·운전 지원의 기반 기술인 자기 경로(ego-path) 검출은 분기부에서 가장 어렵다. 분기기를 통과하면 진로를 결정하는 영역이 시야에서 벗어나 현재 프레임만으로는 진로를 확정할 수 없는 불확실 구간이 발생하며, 선행 연구는 이를 순환 신경망(RNN)으로 보완할 것을 제안하였으나 검증에 필요한 시계열 데이터가 없어 실증되지 못했다. 본 논문은 (1) 이 검증을 가능하게 하는 분기부 평가 데이터셋을 구축하고, (2) 학습형 시간 정련(temporal refinement)이 실제로 이득을 주는지를 학습이 필요 없는 시간 필터와의 통제 비교로 규명한다. 데이터셋은 기관사 시점 영상에서 분기기 통과 장면을 20초 창·4 fps(81 프레임)로 절단한 276개 이벤트로 구성되며, 텀레일 밀착 식별 가능성을 좌우하는 것이 명목 해상도가 아니라 실효 해상도임에 착안하여 고주파 성분 기반 정량 기준을 도입하고 이를 통과한 이벤트만 유지하였다. 평가는 분기기 통과 시각을 기준으로 초 단위 구간(접근, 직후, 불확실, 후기)을 정의하고 라벨 대비 IoU와 정답 없이 측정 가능한 프레임 간 지터를 함께 산출한다. 실험 결과 시간 정보의 이득은 정확도가 아니라 안정성으로만 나타났다. 학습 시퀀스의 프레임 간격을 평가 영상(4 fps)에 맞추면 불확실 구간의 안정성 개선이 +5.7%에서 +14.9%로 2.6배 증가하였으나 정확도는 개선되지 않았고(IoU 손실 -0.0132 대 -0.0140), 이 차이는 학습 도메인 내 지표(Test IoU 0.98480 대 0.98459)로는 전혀 드러나지 않았다. 더 중요한 것은 학습형 정련부가 단순 지수이동평균(EMA)에 크게 못 미친다는 점이다. 거의 동일한 정확도 비용에서(-0.0140 대 -0.0154) EMA는 안정성을 +22.1% 개선하여 학습형 정련부(+3.6%)의 약 6배를 달성하였다. 한편 합성 유사 시퀀스로 학습한 정련부는 정확도를 거의 잃지 않는 대신(-0.0008) 안정성도 거의 제공하지 못해(+1.4%) 사실상 항등 함수로 동작하였다. 즉 0.46 M 파라미터와 별도 학습을 요구하는 출력 수준 정련부는 후처리 필터 대비 정당화되지 않으며, 학습형 시간 모듈은 이동평균 기준선과 비교되어야 한다는 방법론적 함의를 제시한다. 추가로 분기 모호성을 이산 선택으로 재정식화하는 다중 가설 접근의 사전 검증(kill-test)을 수행하여, 가설 간 거리가 0.4 px 수준으로 붕괴하고 상한(oracle) 성능조차 단일 경로를 넘지 못함을 보였다.

핵심어: 자기 경로 검출, 철도 인지, 분기부, 시간적 딥러닝, 평가 데이터셋, 지수이동평균

Abstract

Ego-path detection—identifying the track a train is running on—is hardest at turnouts: once the train passes the switch, the region that determines the route leaves the field of view, creating a period of uncertainty that a single frame cannot resolve. Prior work proposed compensating for this with a

recurrent network but could not verify it for lack of temporal data. This paper (1) constructs a turnout evaluation dataset that makes such verification possible, and (2) determines whether learned temporal refinement actually pays off, through a controlled comparison against training-free temporal filters. The dataset comprises 276 events cut from driver's-eye-view footage as 20 s windows at 4 fps (81 frames each). Observing that whether the switch blade closure is discernible depends not on nominal resolution but on effective resolution, we introduce a quantitative criterion based on high-frequency content and retain only events that pass it. Evaluation defines zones in seconds relative to the switch passage and reports IoU against labels together with inter-frame jitter, which requires no ground truth. We find that temporal information yields stability but not accuracy. Matching the frame interval of the training sequences to the 4 fps evaluation clips raises the stability gain in the uncertain zone from +5.7% to +14.9% ($2.6\times$) without improving accuracy (IoU cost -0.0132 vs -0.0140), and this difference is invisible to in-domain metrics (test IoU 0.98480 vs 0.98459). More importantly, the learned refiner falls far short of a simple exponential moving average (EMA): at essentially the same accuracy cost (-0.0140 vs -0.0154), EMA improves stability by +22.1% against the refiner's +3.6%, roughly a sixfold difference. A refiner trained on synthesised pseudo-sequences, meanwhile, costs almost no accuracy (-0.0008) but delivers almost no stability (+1.4%), behaving as a near-identity function. An output-level refiner requiring 0.46 M parameters and separate training is therefore not justified over a post-processing filter, implying that learned temporal modules must be benchmarked against a moving-average baseline. We additionally report a kill-test of reformulating the branch ambiguity as a discrete choice via multiple hypotheses: the hypotheses collapse to within 0.4 px of each other and even the oracle upper bound fails to exceed the single-path model.

Keywords: ego-path detection, railway perception, turnout, temporal deep learning, evaluation dataset, exponential moving average

1. 서론

전방 카메라 영상에서 열차가 주행 중인 선로, 즉 자기 경로(ego-path)를 검출하는 기술은 철도 자율주행과 운전 지원의 기반이 된다. 자기 경로는 좌·우 두 레일로 표현되며, 관심 영역 한정과 궤도 내 장애물 판정에 직접 활용된다.

자기 경로 검출이 가장 어려운 지점은 분기부다. 분기부는 자기 경로가 둘로 갈라지는 유일한 곳이므로 진로 판단이 가장 중요한데, 정작 열차가 분기기를 통과하면 진로를 결정하는 텅레일 영역이 화면 아래로 벗어나 현재 프레임만으로는 어느 갈래를 택했는지 확인할 수 없다. Laurent[1]는 이 구간을 "불확실 기간(period of uncertainty)"으로 규정하고 순환 신경망(RNN) 결합을 해법으로 제안하였으나, "포괄적인 시계열 데이터셋이 없다"는 이유로 구현·검증하지 못했다.

본 논문은 그 검증을 수행한다. 이를 위해서는 두 가지가 필요하다. 첫째, 분기기 통과 전후를 담은 시계열 평가 데이터다. 둘째, "시간 정보가 이득을 준다"는 주장을 검증할 적절한 비교 기준이다. 후자는 흔히 간과되는데, 학습형 시간 모듈은 통상 단일 프레임 모델과만 비교되며 학습이 필요 없는 시간 필터와는 비교되지 않는다. 그러나 시간적 안정성은 이동평균만으로도 얻을 수 있으므로, 학습형 모듈이 그 기준선을 넘지 못한다면 추가 파라미터와 학습 비용은 정당화되지 않는다.

본 논문의 기여는 다음과 같다.

- 분기부 평가 데이터셋 구축(276 이벤트, 47개 원본 영상, 18개 지역). 분기기 통과 시각 전후 20초를 4 fps로 절단한 81 프레임 시퀀스로 구성하였다.
- 텀레일 식별 가능성의 정량 기준 제시. 모든 프레임이 동일한 명목 해상도(1280×720)를 갖더라도 저화질 원본을 업스케일한 영상은 분기기 세부를 담지 못한다. 고주파 성분 잔차로 실효 해상도를 측정하고 육안 검증으로 임계값을 확정하여 데이터 품질을 관리하였다.
- 시퀀스 프레임 간격 정합의 효과 규명. 학습 시퀀스의 간격을 평가 대상과 맞추면 불확실 구간의 안정성 개선이 2.6배 증가하나 정확도는 개선되지 않으며, 이 차이는 학습 도메인 내 지표로는 전혀 구분되지 않는다.
- 학습형 시간 정련과 이동평균의 통제 비교. 거의 동일한 정확도 비용에서 지수이동평균이 학습형 정련부의 약 6배 안정성을 제공함을 보이고, 학습형 시간 모듈의 평가에 이동평균 기준선을 포함할 것을 제안한다.
- 다중 가설 정식화의 사전 검증(kill-test). 분기 모호성을 이산 선택으로 재정식화하는 접근이 왜 실패하는지를 규명한 부정 결과를 보고한다.

2. 관련 연구

자기 경로 검출. Laurent[1]는 자기 경로 검출을 종단간 딥러닝으로 정식화하고, 백본(ResNet, EfficientNet 계열)과 검출 헤드(회귀/분류/세그멘테이션)의 조합을 비교하였다. 회귀 방식은 좌·우 레일의 앵커별 x좌표와 경로 상한(y-limit)을 직접 예측하여 디코더 없이 낮은 지연시간을 달성한다. 같은 연구는 모호한 상황에서 회귀 모델이 두 궤도의 중간을 예측하는 헤지(hedging) 특성을 관찰하고, 시간 확장의 필요성을 지적하였다.

시간적 확장. 영상 기반 인지에서 시간 정보를 결합하는 방식은 특징맵 수준 융합과 출력 수준 정련으로 나뉜다. 본 연구가 대상으로 삼는 구현은 후자로, 학습된 프레임별 네트워크를 동결한 채 최근 T개 출력 벡터의 시퀀스를 GRU가 읽어 잔차를 예측한다. 출력층을 영행렬로 초기화하여 학습 전에는 프레임별 예측과 동일한 출력을 내도록 설계되어 있다.

시간적 안정화의 비학습 대안. 예측 시계열에 인과적 이동평균이나 지수이동평균을 적용하는 방식은 추가 학습 없이 프레임 간 흔들림을 줄인다. 대가는 지연(lag)이며, 대상이 실제로 변하는 순간에 반응이 늦어진다. 본 논문은 이 고전적 대안을 학습형 정련부와 동일 지표로 비교한다.

철도 인지 데이터셋. RailSem19[2]는 철도 주행 시점 정지 영상 약 8,500장을 제공하는 대표적 공개 데이터셋이고, OSDaR23[3]은 다중 센서로 취득한 연속 주행 시퀀스를 제공한다. 두 데이터셋 모두 분기기 통과 전후를 집중적으로 담고 있지는 않아, 본 논문은 별도의 분기기 평가 데이터셋을 구축하였다.

3. 분기기 평가 데이터셋

3.1 수집과 구성

기관사 시점(cab view) 영상에서 분기기 통과 장면을 선별하여 이벤트 단위로 절단하였다. 한 이벤트는 분기기 통과 시각을 중심으로 전후 20초 창을 4 fps로 표본화한 81 프레임(프레임 간격 0.25초, 폭 1280 px)으로 구성된다. 고정 카메라 촬영물과 모형철도는 제외하였고, 진행 방향으로 궤도가 갈라지는 분기(facing, split) 장면만 유지하고 합류(trailing) 장면은 제외하였다.

최종 데이터셋은 276개 이벤트이며 47개 원본 영상, 18개 지역에서 수집되었다(영국 77, 일본 34, 슬로베니아 25, 독일 22, 한국 19, 스위스 17 등).

3.2 텀레일 식별 가능성 기준: 실효 해상도

분기부 평가에서 본질적인 요구 조건은 텀레일 밀착 여부가 식별 가능한가이다. 그런데 모든 이벤트가 동일한 명목 해상도로 절단되므로 해상도 표기만으로는 이를 판별할 수 없다. 저화질 원본을 업스케일한 영상은 화소 수는 같지만 분기 세부를 담지 못하기 때문이다.

이에 본 논문은 실효 해상도를 다음과 같이 정량화한다. 궤도가 위치하는 중앙-하단 영역을 절반으로 축소했다가 원래 크기로 복원한 뒤 원본과의 평균 절대 차이를 계산한다.

$hi = \text{mean} |I - \text{up}(\text{down}(I, 2), 2)|$, 여기서 I 는 중앙-하단 영역(세로 50-95%, 가로 22-78%)이다.

이 값은 화소율 절반을 넘는 고주파 성분의 양에 해당하므로, 업스케일된 영상에서는 0에 가깝다. 육안 검증을 통해 임계값을 확정하였다: $hi = 2.63$ 에서는 침목이 뭉개져 텀레일 판별이 불가능하였고 $hi = 3.00$ 부터 레일 윤곽과 침목이 분리되어 판별이 가능하였으므로 $hi \geq 3.0$ 을 기준으로 삼았다.



그림 1. 실효 해상도 기준의 효과 (좌: 재추출 전, 우: 재추출 후)

초기 수집분 318개 중 99개(31%)가 기준에 미달하였다. 원인 분석 결과 원본 영상 32편 중 29편이 1080p 이상(4K 10편)이었음에도 수집 과정에서 720p 이하로 내려받은 것이 원인이었다. 따라서 새 영상을 탐색하는 대신 동일 구간을 고해상도로 재추출하여 56개를 복구하였다. 재추출 시 각 이벤트의 원본 시각과 창 정보를 그대로 사용하므로 기존 큐레이션(분기/합류 분류)이 보존된다. 최종적으로 데이터셋 전체가 기준을 통과하며, 재추출본의 실효 해상도 중앙값은 4.89로 삭제 대상이었던 값(2점대)의 약 두 배이다.

3.3 라벨과 평가 표본

평가에는 지역 분포를 고려해 층화 표본으로 선정한 30개 이벤트(2,422 프레임)를 사용한다. 라벨은 SAM 2[4] 비디오 마스크 전파와 학습된 세그멘테이션 모델을 병용하여 생성하고 육안 검수를 거쳤다. 라벨 생성에 사용한 모델은 사전 비교에서 최고 성능을 보인 세그멘테이션 계열 모델이며, 비교 대상인 회귀 계열 모델들과 계열이 달라 특정 비교 대상에 유리하게 작용하지 않는다. 다만 라벨의 상당수가 자동 생성이므로 절대 IoU는 자동 라벨과의 일치도로 해석하고, 본 논문의 결론은 모델 간 상대 비교에 근거한다.

4. 평가 프로토콜

4.1 구간 정의

Laurent[1]가 지정한 불확실 기간은 분기기 통과 이후 수 초에 걸쳐 지속된다. 이를 반영하여 분기기 통과 시각을 원점으로 초 단위 구간을 정의한다.

구간	범위	의미
접근	-6 ~ 0 s	분기부가 전방에 보이는 구간
직후	0 ~ 2.5 s	통과 직후, 경로가 실제로 변하는 구간
불확실	2.5 ~ 6 s	분기부가 시야를 벗어난 뒤 궤도 정렬로 진로가 확인되기 전
후기	6 ~ 10 s	진로가 확정된 이후




그림 2. 이벤트 구조와 평가 구간 정의

구간 경계는 각 이벤트의 표본화율(4 fps)로 프레임 인덱스에 환산한다. 프레임 단위와 초 단위를 혼동하면 구간 폭이 4배로 어긋나므로, 본 프로토콜은 모든 경계를 초로 규정한다.

4.2 지표

- IoU: 예측한 좌·우 레일이 이루는 영역과 라벨 영역의 교집합/합집합.
- 프레임 간 지터: 연속 두 프레임의 예측 경로를 공통 높이 구간에서 비교한 평균 $|\Delta x|$ (px). 정답 라벨이 필요 없으며, 값이 클수록 예측이 불안정하다. Laurent[1]가 불확실성 지표로 활용 가능하다고 제안한 "예측의 주저(hesitancy)"를 정량화한 것에 해당한다.

5. 비교 대상

기준 모델은 EfficientNet-B3 백본의 회귀형 단일 프레임 검출기(base)이며, 여기에 다음을 비교한다.

학습형 시간 정련. base를 동결한 채 최근 5개 출력 벡터(각 129차원)를 GRU(은닉 256, 1층)가 읽어 잔차를 예측하는 정련부(0.46 M 파라미터, base 대비 +3.2%)를 엮는다. 학습 시퀀스 구성에 따라 세 가지를 비교한다.

- rnn: 단일 이미지에서 크롭 창을 보간해 만든 합성 유사 시퀀스로 학습(선행 구현의 기본값).
- rnn-1fps: 연속 주행 영상(OSDaR23, 10 fps)에서 stride 10으로 표본화한 실제 시퀀스(1 fps)로 학습.
- rnn-4fps: 동일 영상에서 stride 3으로 표본화(3.33 fps)하여 평가 영상의 4 fps에 근접시킨 시퀀스로 학습.

rnn-1fps와 rnn-4fps는 표본화 간격만 다르고 나머지 설정(가림 증강 확률 0.5, 300 에폭, 배치 32, base 동결)이 동일한 통제쌍이다. 추가로 분기부 가림을 모사하는 증강으로 학습한 rnn-occ를 포함한다.

학습 불필요 시간 필터. base의 원시 예측 벡터에 인과적 필터를 적용한다. 크롭 창이 프레임마다 이동하므로 과거 예측을 현재 좌표계로 재투영한 뒤 결합한다.

- boxcar-K: 최근 K개 예측의 단순 평균.

- EMA- α : $\text{out}[t] = \alpha \cdot x[t] + (1-\alpha) \cdot \text{out}[t-1]$, $\text{out}[0] = x[0]$.

6. 실험 결과

6.1 구간별 결과

표 1-3은 30개 이벤트(2,422 라벨 프레임)에 대한 결과이다.

표 1. 구간별 프레임 간 지터(px, 괄호는 base 대비 개선율)

모델	접근 -6~0 s	직후 0~2.5 s	불확실 2.5~6 s	후기 6~10 s
base	2.96	2.45	3.22	3.18
rnn	2.96 (-0.2%)	2.46 (-0.3%)	3.07 (+4.5%)	3.14 (+1.3%)
rnn-occ	4.15 (-40.6%)	2.82 (-15.1%)	3.78 (-17.6%)	4.08 (-28.3%)
rnn-1fps	3.11 (-5.3%)	2.30 (+5.8%)	3.03 (+5.7%)	3.12 (+1.8%)
rnn-4fps	3.13 (-5.8%)	2.41 (+1.6%)	2.74 (+14.9%)	3.10 (+2.4%)
base+boxcar3	2.54 (+14.2%)	1.92 (+21.5%)	2.46 (+23.6%)	2.56 (+19.4%)
base+EMA0.5	2.45 (+17.3%)	1.93 (+21.2%)	2.44 (+24.0%)	2.37 (+25.4%)
base+boxcar5	2.41 (+18.6%)	1.73 (+29.4%)	2.16 (+32.8%)	2.17 (+31.7%)

표 2. 구간별 IoU(라벨 대비)

모델	접근	직후	불확실	후기
base	0.9562	0.9598	0.9445	0.9481
rnn	0.9538	0.9577	0.9465	0.9471
rnn-occ	0.9462	0.9542	0.9399	0.9399
rnn-1fps	0.9378	0.9470	0.9361	0.9346
rnn-4fps	0.9371	0.9472	0.9325	0.9358
base+boxcar3	0.9356	0.9372	0.9322	0.9314
base+EMA0.5	0.9365	0.9400	0.9349	0.9354
base+boxcar5	0.9108	0.9150	0.9095	0.9071
(프레임 수 n)	720	300	420	480

표 3. 구간 평균 요약 및 효율

모델	지터	안정성 개선	IoU	IoU 손실	효율(개선율/손실)
base	2.95	기준	0.9521	—	—
rnn	2.91	+1.4%	0.9513	-0.0008	(효과 미미)
rnn-occ	3.71	-25.7%	0.9450	-0.0071	음(악화)
rnn-1fps	2.89	+1.9%	0.9389	-0.0132	144
rnn-4fps	2.84	+3.6%	0.9382	-0.0140	259
base+boxcar3	2.37	+19.7%	0.9341	-0.0180	1,094
base+EMA0.5	2.30	+22.1%	0.9367	-0.0154	1,434
base+boxcar5	2.12	+28.2%	0.9106	-0.0415	680

전체를 관통하는 관찰은 시간 정보의 이득이 정확도가 아니라 안정성으로만 나타난다는 것이다. 표 2에서 어떤 시간 모델도 base의 IoU를 상회하지 못하며(불확실 구간의 rnn이 유일한 예외, +0.0020), 표 1에서는 여러 방법이 뚜렷한 안정성 개선을 보인다.

6.2 시퀀스 간격 정합의 효과

rnn-1fps와 rnn-4fps는 표본화 간격만 다른 통제쌍이다. 간격을 평가 영상(0.25초)에 근접시키면 불확실 구간의 안정성 개선이 +5.7%에서 +14.9%로 2.6배 증가한다. 이는 시간 정보가 실제로 필요한 구간에서 정합의 효과가 집중적으로 나타남을 뜻한다.

반면 정확도는 개선되지 않았다(IoU 손실 -0.0132 대 -0.0140으로 사실상 동일). 즉 간격 정합은 정련부가 과거 궤적을 더 잘 활용하도록 만들지만, 그 활용이 정확도로 환산되지는 않는다.

주목할 점은 이 차이가 학습 도메인 내 지표로는 전혀 드러나지 않는다는 것이다. 두 모델의 학습 도메인 테스트 IoU는 0.98480과 0.98459, 최저 검증 손실은 0.02070과 0.02073으로 구분되지 않는다. 시간 모델의 거동은 시퀀스의 시간 구조에 의존하므로, 프레임 간격이 다른 도메인에 적용할 때 인도메인 지표만으로 판단해서는 안 된다.

6.3 학습형 정련 대 이동평균

표 3의 효율 열은 정확도 1단위를 지불하고 얻는 안정성 개선율이다. rnn-4fps는 259, EMA0.5는 1,434로 약 5.5배 차이가 난다. 절대량으로 보면 두 방법의 정확도 비용은 -0.0140과 -0.0154로 거의 같은 반면, 안정성 개선은 +3.6%와 +22.1%로 약 6배 차이이다.

한편 합성 유사 시퀀스로 학습한 rnn은 정확도를 거의 잃지 않지만(-0.0008) 안정성도 거의 주지 못한다(+1.4%). 이는 잔차 구조의 정련부가 항등 함수에 가깝게 수렴했음을 시사하며, 학습형 정련부가 취하는 두 가지 상태 — 아무것도 하지 않거나(rnn), 이동평균만큼 정확도를 쓰고 훨씬 적게 돌려주거나(rnn-4fps) — 를 보여준다.

평활의 강도에 따른 거동도 확인된다. 강한 평활(boxcar5)은 안정성을 가장 크게 개선하지만 정확도를 -0.0415 잃어 효율이 680으로 떨어진다. 지수 감쇠를 쓰는 EMA가 동일 창 길이의 단순 평균(boxcar3, 효율 1,094)보다 효율이 높은 것도, 오래된 관측을 약하게 반영하여 지연 비용을 줄이기 때문으로 해석된다.

그림 3은 불확실 구간의 연속 3 프레임(간격 0.25초)에서 세 방법의 예측을 비교한 것이다. 단일 프레임 모델(base)은 프레임마다 경로가 크게 이동하는 반면, 학습형 정련(rnn)은 그 이동을 부분적으로만 완화하고, EMA는 세 프레임에 걸쳐 일관된 경로를 유지한다.



그림 3. 불확실 구간 연속 프레임에서의 예측 비교 (위: base, 가운데: rnn, 아래: EMA0.5)

결론적으로 0.46 M 파라미터와 별도의 시퀀스 학습을 요구하는 출력 수준 정련부는, 후처리 한 줄로 구현되는 지수이동평균 대비 정당화되지 않는다. 학습형 시간 모듈을 제안하는 연구는 단일 프레임 기준선뿐 아니라 이동평균 기준선과의 비교를 포함해야 한다.

6.4 가림 증강의 재검토

rnn-occ는 모든 구간에서 최하위(지터 -25.7%, IoU -0.0071)이다. 이 모델은 시퀀스의 마지막 프레임 하단을 인위적으로 차폐하고 타킷은 유지하는 증강으로 학습되어, 합성 폐색 조건에서는 회복 효과가 보고된 바 있다. 그러나 폐색이 없는 실제 분기부 영상에서는 성능이 저하된다.

원인은 증강이 모사하는 실패 모드와 실제 실패 모드의 불일치로 해석된다. 하단 차폐는 "경로가 화면에서 가려진" 상황을 학습시키지만, 분기부의 불확실성은 경로가 보이지 않는 문제가 아니라 두 갈래 중 어느 쪽인지 모르는 이산적 모호성이다. 실제 분기부 영상에서 레일은 계속 관측된다. 결과적으로 이 증강은 정련부를 항등에서 멀어지게 만들지만, 그 이탈 방향이 실제 상황과 맞지 않아 순손실이 된다. 정련부가 base 예측에서 크게 이탈할수록(rnn 2.36 px, rnn-occ 5.87 px 평균 이탈) IoU가 단조 감소하는 경향도 이를 뒷받침한다.

6.5 다중 가설 정식화의 사전 검증

분기부의 모호성이 이산 선택이라는 관찰에 따라, 경로를 하나가 아닌 K개 가설로 출력하고 승자독식(winner-takes-all) 손실로 학습하여 헤지 대신 양 갈래를 모두 보존하는 접근을 검토하였다. 최종 완전연결층만 K배로 확장하고($K=2$, 파라미터 +0.27 M) 손실이 최소인 가설에만 회귀 기울기를 주며, 패자에는 소량 가중치($\epsilon=0.05$)를 유지하였다.

전면 구현에 앞서 상한 검증(kill-test)을 수행하였다. K개 중 최선을 고른다고 가정한 oracle IoU가 단일 경로 대비 유의하게 높지 않다면 어떤 선택자를 설계해도 이득이 없기 때문이다.

표 4. 다중 가설 상한 검증($K=2$)

구간	단일 경로	점수 선택	oracle	oracle - 단일	가설 간 거리	n
접근	0.9562	0.9538	0.9551	-0.0011	0.47 px	720
직후	0.9598	0.9586	0.9601	+0.0003	0.43 px	300
불확실	0.9445	0.9349	0.9365	-0.0080	0.41 px	420
후기	0.9481	0.9450	0.9463	-0.0018	0.42 px	480

결과는 부정적이다. oracle이 단일 경로를 넘는 구간이 없으며(최대 +0.0003), 두 가설 간 거리는 0.41–0.47 px로 사실상 동일한 경로로 붕괴하였다.

원인은 학습 분포의 성질에 있다. 승자독식 학습이 가설을 특화시키려면 이미지 조건부 분포가 다봉이어야 하는데, 분기기의 텅레일 방향은 이미지에 관측 가능하므로 대부분의 학습 이미지에서 정답 갈래가 결정된다. 진정으로 모호한 프레임은 분기부가 시야를 벗어난 이후뿐이며, 정지 영상 위주의 학습 데이터에는 그러한 프레임이 희소하다. 따라서 이 접근이 유효하려면 모호한 프레임으로 학습해야 하는데, 그 데이터는 본 논문이 구축한 평가셋과 동일한 성격이어서 학습에 사용하면 평가셋이 소진된다.

7. 논의

7.1 출력 수준 정련의 한계

세 가지 시퀀스 구성 모두에서 학습형 정련부의 이득은 제한적이었다. 근본 원인은 정련부가 관측하는 정보의 빈곤에 있다. 이 구조는 프레임별 네트워크의 129차원 출력 벡터만을 입력받으므로, 영상 근거를 직접 활용하지 못하고 과거 예측의 궤적만으로 현재 예측을 보정한다. 현재 프레임이 명확할 때 최적해는 항등이며, 실제로 학습된 정련부의 base 대비 평균 이탈은 2.36 px에 불과하다.

반면 이동평균은 동일한 정보(과거 예측)만으로도 더 큰 안정성을 얻는다. 학습된 GRU가 이를 넘어서지 못한다는 사실은, 이 문제에서 시간 정보로부터 추출할 수 있는 이득이 이미 단순 평활로 거의 소진됨을 시사한다. 시간 정보가 실질적 이득을 주려면 특징맵 수준 융합이나 불확실성 게이팅(예측이 흔들릴 때만 평활 강도를 높이는 적응적 필터) 등 다른 결합 방식을 검토해야 한다.

7.2 평가 재현성: 추론 경로와 좌표계의 일치

평가 파이프라인을 구축하며 재현성을 해치는 두 부류의 문제를 발견하였다.

추론 경로 불일치. 자동 라벨 생성 경로가 참조 구현(detect.py)과 세 가지 점에서 달랐다. (1) 크롭 모드: 참조 구현의 기본값은 자동 크롭이나 라벨 생성 경로는 크롭 없이 동작하여, 동일 프레임에서 검출 도달 거리가 $y=491$ 에서 $y=429$ 로 차이가 났다. 모델이 크롭된 입력으로 학습되므로 이 불일치가 가장 큰 영향을 미쳤다. (2) 폴리라인 단순화: 저장 직전 RDP 알고리즘($\epsilon=10$ px)이 적용되어 직선 구간 레일이 2–3점으로 축약되었으며, 조밀한 라벨 대비 IoU가 평균 0.02 낮게 측정되었다. (3) 시간 상태: 프레임마다 초기화되어 시간 모델을 선택해도 시간 정보가 무력화되었다.

좌표계 불일치. 데이터 편집 기능(프레임 일괄 크롭)과 평가 자산(사전 계산된 예측)이 분리되어 있어, 프레임을 크롭한 뒤 예측을 갱신하지 않으면 라벨과 예측이 서로 다른 좌표계에 놓인다. 본 연구에서는 평가 표본 30개 중 6개가 이상태였고 그중 한 이벤트는 IoU가 0으로 계산되어, 전체 평균을 0.03 가량 왜곡하고 있었다. 지표가 이상해 보일 때까지 드러나지 않는 조용한 오류이므로, 프레임을 변경하는 연산은 파생 자산(예측·라벨·썸네일)의 무효화를 함께 수행해야 한다.

모델 간 IoU 차이가 ± 0.005 수준인 평가에서 이러한 불일치는 신호를 가릴 수 있다. 라벨 생성과 평가는 동일한 추론 경로를 사용하고, 데이터 편집은 파생 자산과 원자적으로 연동되어야 한다.

7.3 한계

첫째, 라벨의 상당수가 자동 생성이므로 절대 IoU는 자동 라벨과의 일치도로 해석해야 한다. 라벨 생성 모델이 비교 대상과 다른 계열이어서 상대 비교의 편향은 제한적이나, 완전한 수동 라벨에 기반한 재검증이 필요하다.

둘째, 평가는 30개 이벤트(2,422 프레임)에 대한 것으로, 구간별 프레임 수가 299–719 범위이다. 관찰된 차이 중 IoU ± 0.002 수준은 통계적 유의성을 별도로 검토해야 한다.

셋째, 학습에 사용한 연속 시퀀스는 OSDaR23의 정거장 구내 장면으로 분기부 통과 장면이 풍부하지 않다. 분기부 시퀀스로 직접 학습한 시간 모델의 성능은 본 논문의 범위를 벗어난다.

8. 결론

본 논문은 철도 자기 경로 검출에서 분기부 불확실 구간을 시간 정보로 보완할 수 있는지를 검증하기 위해, 분기기 통과 장면 276개 이벤트로 구성된 평가 데이터셋을 구축하고 학습형 시간 정련과 학습 불필요 시간 필터를 통제 비교하였다. 텅레일 식별 가능성을 좌우하는 것이 명목 해상도가 아니라 실효 해상도임을 밝히고 고주파 성분 기반 정량 기준을 데이터 품질 관리에 도입하였다.

실험 결과 시간 정보의 이득은 정확도가 아니라 안정성으로만 나타났다. 어떤 시간 모델도 단일 프레임 기준선의 IoU를 유의하게 상회하지 못한 반면, 프레임 간 지터는 여러 방법에서 뚜렷이 감소하였다. 학습 시퀀스의 프레임 간격을 평가 대상과 맞추면 불확실 구간의 안정성 개선이 2.6배 증가하나 정확도는 개선되지 않으며, 이 차이는 학습 도메인 내 지표로는 드러나지 않는다.

가장 중요한 결과는 학습형 정련부가 단순 지수이동평균에 크게 못 미친다는 것이다. 거의 동일한 정확도 비용에서 EMA가 약 6배의 안정성 개선을 제공하며, 정확도 1단위당 효율로는 5.5배 차이가 난다. 합성 시퀀스로 학습한 정련부는 항등 함수에 가깝게 수렴하여 비용도 이득도 거의 없다. 따라서 0.46 M 파라미터와 별도 학습을 요구하는 출력 수준 시간 정련은 후처리 필터 대비 정당화되지 않는다.

이는 Laurent[1]가 제안만 하고 검증하지 못한 시간 확장에 대한 실증적 답이자, 학습형 시간 모듈의 평가에 이동평균 기준선을 포함해야 한다는 방법론적 제안이다. 향후 연구로는 예측 벡터만이 아니라 영상 근거를 함께 활용하는 특징맵 수준의 시간 융합, 예측 불확실성에 따라 평활 강도를 조절하는 적응적 필터, 그리고 도메인 적응을 통한 기본 정확도 향상을 제시한다. 특히 본 논문의 측정에서 시간축 개선 폭이 IoU 기준 ± 0.005 수준인 반면 학습 도메인(테스트 IoU 0.98)과 평가 도메인(0.95) 간 격차는 그보다 훨씬 크므로, 절대 성능 향상 관점에서는 도메인 적응의 우선순위가 높다.

감사의 글

(생략)

참고문헌

- [1] T. Laurent, "Train Ego-Path Detection on Railway Tracks Using End-to-End Deep Learning," arXiv preprint arXiv:2403.13094, 2024.
- [2] O. Zendel, M. Murschitz, M. Zeilinger, D. Steininger, S. Abbasi, and C. Beleznai, "RailSem19: A Dataset for Semantic Rail Scene Understanding," in Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition Workshops (CVPRW), Long Beach, CA, USA, 2019, pp. 1221–1229.
- [3] R. Tagiew et al., "OSDaR23: Open Sensor Data for Rail 2023," arXiv preprint arXiv:2305.03001, 2023.
- [4] N. Ravi et al., "SAM 2: Segment Anything in Images and Videos," arXiv preprint arXiv:2408.00714, 2024.
- [5] M. Tan and Q. V. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," in Proc. 36th Int. Conf. Machine Learning (ICML), Long Beach, CA, USA, 2019, pp. 6105–6114.
- [6] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," in Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR), Las Vegas, NV, USA, 2016, pp. 770–778.
- [7] C. Rupprecht et al., "Learning in an Uncertain World: Representing Ambiguity Through Multiple Hypotheses," in Proc. IEEE Int. Conf. Computer Vision (ICCV), Venice, Italy, 2017, pp. 3591–3600.
- [8] K. Cho et al., "Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation," in Proc. Conf. Empirical Methods in Natural Language Processing (EMNLP), Doha, Qatar, 2014, pp. 1724–1734.
- [9] D. H. Douglas and T. K. Peucker, "Algorithms for the Reduction of the Number of Points Required to Represent a Digitized Line or its Caricature," Cartographica, vol. 10, no. 2, pp. 112–122, 1973.

※ 학술지 투고 시 각 문헌의 권·호·페이지 및 DOI를 최종 확인·보완할 것.